



東南大學

模式识别与机器学习课程设计

基于局部尺度谱图与模块度选择的手写数字聚类

姓名：待填写

学号：待填写

专业：未来机器人

2026 年 6 月 11 日

摘要

手写数字图像具有书写倾斜、类内差异大和类别边界非线性的特点，标准 K-means 的球形簇假设难以充分描述其流形结构。本文提出一种基于图像矩倾斜校正、局部尺度谱图、模块度重启选择和邻域一致性细化的无监督聚类方法。首先利用二阶图像矩估计水平剪切量并校正数字倾斜；随后构建自适应局部尺度的 k 近邻图，通过归一化图拉普拉斯矩阵得到谱嵌入；在谱空间中执行自主实现的 K-means++，并以原始邻域图的模块度而非欧氏惯性选择重启结果；最后通过邻域多数投票修正局部不一致样本。参数选择与模型训练均不使用真实类别标签，标签仅用于实验结束后的客观评价。

在 scikit-learn Digits 数据集的 1797 幅图像上，本文方法取得 95.55% 的聚类准确率、92.35% 的归一化互信息和 90.63% 的调整兰德指数。10 个随机种子下的平均准确率为 $95.59\% \pm 0.02\%$ 。相较原始 K-means，准确率提高 16.36 个百分点；消融实验表明各改进模块均产生正向贡献。

关键词：手写数字聚类；谱聚类；K-means++；局部尺度；模块度；DBSCAN

目录

1	选题背景	4
1.1	应用背景与重要性	4
1.2	问题定义	4
1.3	选题依据	4
2	相关算法	4
2.1	K-means 与 K-means++	4
2.2	DBSCAN	5
2.3	谱聚类	5
3	本文方法	5
3.1	整体流程	5
3.2	基于图像矩的倾斜校正	5
3.3	局部尺度 kNN 图	6
3.4	归一化谱嵌入	6
3.5	基于模块度的重启选择	7
3.6	邻域一致性细化	7
3.7	算法复杂度	7
4	软件实现	7
4.1	开发环境	7
4.2	代码结构与原创性	7
5	实验设计	8
5.1	数据集	8
5.2	评价指标	8
5.3	参数与对比方法	8
6	实验结果与分析	9
6.1	总体结果	9
6.2	DBSCAN 分析	10
6.3	消融实验	10
6.4	参数敏感性与无标签选择	11
6.5	随机稳定性	12
6.6	混淆矩阵与误差分析	12
7	创新点总结	13

8 实践总结与心得体会	13
9 结论与展望	13

1 选题背景

1.1 应用背景与重要性

手写数字识别是模式识别的典型任务，可用于邮政编码读取、票据处理、表单录入和档案数字化。实际数据往往缺少完整标签，而人工标注成本较高，因此无监督聚类可作为数据预分类、异常检测和半自动标注的基础环节。

与监督分类不同，聚类算法只能依靠样本之间的结构关系发现类别。手写数字存在明显的类内差异，例如同一个数字的倾斜方向、笔画粗细和书写位置不同；同时也存在较强的类间相似性，例如数字 1 与 7、3 与 8、4 与 9。该任务能够综合考察特征预处理、距离度量、图模型、迭代优化和无监督评价等课程知识。

1.2 问题定义

给定图像集合 $\mathcal{X} = \{\mathbf{x}_i\}_{i=1}^N$ ，其中 $\mathbf{x}_i \in \mathbb{R}^{64}$ 为 8×8 灰度图像展开得到的向量，目标是在训练时不访问真实标签的条件下，将全部样本划分为 $K = 10$ 个簇。真实数字标签仅用于实验结束后计算 ACC、NMI 和 ARI。

1.3 选题依据

课程评分同时强调完成度、创新度和原创度。本文选择手写数字图像聚类，原因如下：

1. 数据规模适中，可在普通计算机上完整运行参数实验和消融实验；
2. K-means、K-means++、DBSCAN、PCA、HOG 和本文核心谱图流程均可独立实现；
3. 数据集带有评价标签，但训练阶段不依赖标签，便于客观比较不同聚类假设；
4. 标准 K-means 存在明确局限，为图结构建模和无监督结果选择提供了改进空间。

2 相关算法

2.1 K-means 与 K-means++

K-means 将每个样本分配到最近的聚类中心，并最小化簇内平方误差 [1]：

$$J = \sum_{i=1}^N \|\mathbf{x}_i - \boldsymbol{\mu}_{z_i}\|_2^2, \quad (1)$$

其中 z_i 为样本 i 的簇编号, μ_{z_i} 为对应中心。算法交替执行样本分配和中心更新, 直到中心移动量低于阈值。K-means++ 按样本到已有中心的平方距离进行概率采样, 降低随机初始化产生较差局部解的概率 [2]。

K-means 计算简单, 但隐含簇近似球形、尺度相近且可由欧氏中心表示的假设。手写数字在像素空间中往往分布于弯曲的低维流形, 因此该假设并不充分。

2.2 DBSCAN

DBSCAN 根据邻域半径 ϵ 和最小邻域样本数 `min_samples` 区分核心点、边界点与噪声点 [3]。其优点是不需要预先指定簇数, 并能够发现非凸簇; 缺点是对距离尺度和密度差异敏感。高维空间中的距离集中现象会进一步增加 ϵ 的选择难度。

2.3 谱聚类

谱聚类将样本表示为图节点, 通过图拉普拉斯矩阵的特征向量获得低维嵌入, 再对嵌入进行聚类 [4, 5]。与直接在像素空间执行 K-means 相比, 谱方法能够利用局部邻接关系描述非线性流形。不过, 标准谱聚类通常采用固定邻域权重, 对局部密度变化较敏感, 聚类离散化阶段也仍可能受到 K-means 局部解影响。

3 本文方法

3.1 整体流程

本文方法包含五个步骤:

1. 使用二阶图像矩估计并校正每幅图像的水平倾斜;
2. 构建带局部自适应尺度的 kNN 加权图;
3. 对归一化图拉普拉斯矩阵进行特征分解, 得到谱嵌入;
4. 多次运行 K-means++, 以图模块度选择最佳无监督划分;
5. 在原始 kNN 邻域中执行有限步多数投票, 修正局部不一致标签。

3.2 基于图像矩的倾斜校正

设灰度图像为 $I(x, y)$, 总灰度质量为 m_{00} , 质心为 $(\bar{x}, \bar{y})$ 。计算中心矩

$$\mu_{11} = \frac{1}{m_{00}} \sum_{x,y} (x - \bar{x})(y - \bar{y})I(x, y), \quad (2)$$

$$\mu_{02} = \frac{1}{m_{00}} \sum_{x,y} (y - \bar{y})^2 I(x, y). \quad (3)$$

水平剪切系数定义为 $a = \mu_{11} / \max(\mu_{02}, \epsilon)$ ，校正坐标为

$$x' = x - a(y - \bar{y}). \quad (4)$$

离散位置使用线性插值。该步骤降低同一数字因倾斜方向不同造成的像素距离。




图 1: 原始图像与倾斜校正结果示例

3.3 局部尺度 kNN 图

对每个样本搜索 k 个最近邻。固定高斯核带宽无法同时适应稠密区域和稀疏区域，因此采用局部尺度思想 [6]。令 σ_i 为样本 i 到其第 l 个近邻的距离，则有向边权为

$$\tilde{w}_{ij} = \exp \left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|_2^2}{\max(\sigma_i \sigma_j, \epsilon)} \right). \quad (5)$$

本文使用并图进行对称化：

$$w_{ij} = \max(\tilde{w}_{ij}, \tilde{w}_{ji}). \quad (6)$$

该设计既保留局部邻接，又避免互惠 kNN 图在小邻域下产生大量断开分量。

3.4 归一化谱嵌入

记邻接矩阵为 W ，度矩阵为 D ，其中 $D_{ii} = \sum_j w_{ij}$ 。构造对称归一化拉普拉斯矩阵

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}. \quad (7)$$

取最小的 K 个特征值对应的特征向量组成矩阵 $U \in \mathbb{R}^{N \times K}$ ，并对每一行进行 ℓ_2 归一化，得到谱嵌入 Y 。该嵌入将图上连接紧密的样本映射到相近位置，使非凸结构更接近可由 K-means 划分的形态。

3.5 基于模块度的重启选择

普通 K-means++ 多次重启后通常选择谱空间惯性最小的结果。但实验发现，谱空间中的最小欧氏惯性不一定对应原始图上的最佳分区。本文改为在每次重启后计算图模块度 [7]：

$$Q = \sum_{c=1}^K \left[\frac{W(V_c, V_c)}{\sum_{i,j} w_{ij}} - \left(\frac{\text{vol}(V_c)}{\sum_{i,j} w_{ij}} \right)^2 \right], \quad (8)$$

其中 V_c 表示第 c 个簇， $W(V_c, V_c)$ 为簇内边权之和， $\text{vol}(V_c)$ 为簇内节点度之和。最终选择 Q 最大的重启结果。该准则只依赖无标签邻域图，同时使离散化目标与谱建模目标保持一致。

3.6 邻域一致性细化

谱离散化后，少量边界样本可能与局部邻居标签不一致。对每个样本取最近的 r 个邻居，使用多数投票更新标签：

$$z_i^{(t+1)} = \arg \max_c \sum_{j \in \mathcal{N}_r(i)} \mathbb{I}(z_j^{(t)} = c). \quad (9)$$

本文仅执行有限步更新，避免过度平滑导致小簇被吞并。

3.7 算法复杂度

kNN 搜索在直接实现下约为 $O(N^2d)$ ；稀疏图特征分解主要与边数 Nk 和目标特征向量数 K 有关；谱空间 K-means++ 每次迭代约为 $O(NK^2)$ 。Digits 数据集规模较小，完整方法单次运行约 0.47 秒。对于更大数据集，可使用近似近邻搜索和 Nystrom 近似降低计算与存储成本。

4 软件实现

4.1 开发环境

实验环境为 Windows、Python 3.11、NumPy 2.4、SciPy 1.17、scikit-learn 1.9、pandas 3.0 和 Matplotlib 3.10。项目使用 uv 管理依赖并生成锁文件。报告使用 MiKTeX 25.12、XeLaTeX 和 BibTeX 编译。

4.2 代码结构与原创性

核心实现位于 `src/prml_project/`：

- `data.py`：加载 Digits 数据集；

- `features.py`: 倾斜校正、HOG、PCA 和标准化;
- `clustering.py`: K-means、K-means++、DBSCAN 和本文谱方法;
- `metrics.py`: ACC、NMI、ARI、覆盖率等指标;
- `experiments.py`: 基准、消融、敏感性、稳定性和图表生成。

K-means、K-means++、DBSCAN、PCA、HOG、局部尺度图、谱嵌入、模块度选择和邻域细化均在项目中独立实现。scikit-learn 主要用于公开数据加载、标准指标, 以及 GMM 和标准谱聚类外部基线。全部实验由配置文件控制, 固定随机种子并输出 CSV。

5 实验设计

5.1 数据集

Digits 数据集包含 1797 幅 8×8 灰度手写数字图像, 共 10 类, 每个像素取值范围为 0 至 16。程序加载后将其归一化到 $[0, 1]$ 。数据集由 scikit-learn 内置提供, 不需要额外下载, 也不随最终代码提交。

5.2 评价指标

由于聚类编号与真实类别编号不存在固定对应关系, ACC 使用匈牙利算法寻找最佳一一映射 [8]。同时报告 NMI 和 ARI[9]。对于 DBSCAN, 还报告:

- 全样本 ACC: 噪声点计为错误;
- 条件 ACC: 仅在非噪声样本上计算;
- 覆盖率: 非噪声样本占全部样本的比例。

这种评价方式避免通过丢弃困难样本虚增 DBSCAN 准确率。

5.3 参数与对比方法

本文方法设簇数 $K = 10$, 候选近邻数 $k \in \{5, 7, 10, 15, 20, 25, 30\}$, 局部尺度位置 $l \in \{1, 2, 3, 5, 7\}$ 。每组参数执行 100 次 K-means++ 重启, 并按模块度选择结果。参数 $(k, l) = (7, 2)$ 在候选集合中取得最高模块度, 因此无需真实标签完成选择。邻域细化使用 5 个近邻并迭代 3 步。

对比方法包括原始像素 K-means、PCA K-means++、HOG K-means++、DBSCAN、高斯混合模型和标准 kNN 谱聚类。DBSCAN 取 $\varepsilon = 1.05$ 、`min_samples=3`。

6 实验结果与分析

6.1 总体结果

表 1: 不同聚类方法的全量实验结果

方法	ACC	NMI	ARI	轮廓系数	覆盖率	时间/s
原始像素 K-means	0.7919	0.7409	0.6658	0.1824	1.0000	1.093
PCA + K-means++	0.7930	0.7413	0.6671	0.2127	1.0000	0.577
HOG + K-means++	0.8013	0.6868	0.6324	0.0793	1.0000	1.016
DBSCAN + PCA	0.7045	0.7787	0.6446	0.1110	0.8603	0.028
高斯混合模型	0.8353	0.8129	0.7279	0.2032	1.0000	2.483
标准谱聚类	0.8742	0.8466	0.7913	0.1764	1.0000	0.621
本文方法	0.9555	0.9235	0.9063	0.1661	1.0000	0.466




图 2: 不同方法的 ACC、NMI 和 ARI 对比

本文方法的 ACC 比原始 K-means 提高 16.36 个百分点，比标准谱聚类提高 8.12 个百分点。这说明主要收益并非单纯来自谱分解，而是来自倾斜校正、局部尺度图、模块度选择和邻域细化的共同作用。

轮廓系数最高的方法并非本文方法，这并不矛盾。轮廓系数基于当前特征空间中的欧氏距离，而本文方法优化的是邻域图上的流形结构；手写数字类别不一定对应欧氏空间中的球形高间隔簇。该现象也说明不能仅依赖单一内部指标评价聚类。

6.2 DBSCAN 分析

DBSCAN 的非噪声条件 ACC 为 0.8189，但覆盖率为 0.8603，全样本 ACC 下降到 0.7045，并产生 20 个簇而非 10 个簇。其 k-distance 曲线如 Figure 3 所示。结果表明 DBSCAN 能识别部分高密度核心样本，但不同数字及不同书写风格的局部密度不一致，单一 ε 容易同时产生簇碎裂和噪声点。




图 3: PCA 特征上的 5-NN 距离曲线

6.3 消融实验

表 2: 本文方法的逐模块消融结果

配置	ACC	NMI	ARI
A0: 原始像素 K-means++	0.7919	0.7409	0.6658
A1: A0 + 倾斜校正	0.8002	0.7585	0.6811
A2: 原图 + 局部尺度谱图	0.9087	0.8459	0.8066
A3: A2 + 倾斜校正	0.9149	0.8540	0.8199
A4: A3 + 邻域一致性细化	0.9555	0.9235	0.9063




图 4: 逐模块消融实验的 ACC

局部尺度谱图贡献最大, 使 ACC 从 0.7919 提高至 0.9087, 说明数字图像的局部流形关系比全局欧氏中心更适合该任务。倾斜校正 K-means 和谱方法上均产生稳定增益。邻域细化进一步提高 4.06 个百分点, 表明谱离散化后的主要错误集中于局部边界样本。

6.4 参数敏感性与无标签选择




图 5: 近邻数与局部尺度位置的 ACC 敏感性

表 3: 模块度较高的参数配置

k	l	模块度 Q	ACC	NMI
7	2	0.8924	0.9555	0.9235
7	7	0.8911	0.9366	0.8989
7	3	0.8893	0.9360	0.8971
10	3	0.8873	0.9393	0.9055
10	7	0.8870	0.9393	0.9055

候选配置中，最高模块度对应的 $(k, l) = (7, 2)$ 同时取得最高外部评价结果，说明模块度能够在不访问真实标签的条件下提供有效选择依据。过小的邻域可能导致图连接不足，过大的邻域则会引入跨类别边，使局部流形结构被平滑。

6.5 随机稳定性

在随机种子 0 至 9 上重复完整实验，ACC、NMI、ARI 的均值和总体标准差分别为

$$\text{ACC} = 0.95593 \pm 0.00022, \quad (10)$$

$$\text{NMI} = 0.92471 \pm 0.00060, \quad \text{ARI} = 0.90735 \pm 0.00049. \quad (11)$$

ACC 最小值为 0.95548，最大值为 0.95604。较小方差说明模块度重启选择显著降低了 K-means++ 初始化造成的不稳定性。

6.6 混淆矩阵与误差分析




图 6: 原始 K-means (左) 与本文方法 (右) 的归一化混淆矩阵

本文方法正确聚类 1717 个样本，错误 80 个。主要混淆包括：27 个数字 1 被映射到数字 0 对应簇，13 个数字 7 被映射到数字 9 对应簇，以及 13 个数字 3 被映射到数

字 2 对应簇。这些样本通常存在闭合笔画、顶部横线或尾部弯曲等相似局部结构。与基线相比，本文方法的对角线明显集中，但硬聚类仍无法表达少量处于类别过渡区域的模糊样本。

7 创新点总结

本文创新不依赖深度预训练模型，核心改进均可解释并具有对应消融证据：

1. 将图像矩倾斜校正引入无监督数字聚类，减少书写姿态造成的类内差异；
2. 使用样本局部邻域距离定义自适应图权重，适应不同数字的密度变化；
3. 提出以原始邻域图模块度选择谱空间 K-means++ 重启结果，替代与图目标不一致的最小欧氏惯性准则；
4. 使用有限步邻域一致性细化处理局部边界错误，并通过消融验证其作用；
5. 建立包含 DBSCAN 噪声覆盖率、参数敏感性和多随机种子稳定性的完整评价协议。

8 实践总结与心得体会

本次实践最重要的认识是：较高的算法复杂度不等于更好的聚类结果，评价协议和建模假设更为关键。最初对每个像素进行方差标准化会放大几乎恒定的背景像素，使 K-means 基线被明显低估；修正预处理后，原始像素 K-means 已达到约 79% ACC。

第二个认识是内部优化目标必须与模型结构一致。在谱空间中简单选择惯性最小的 K-means 重启，可能得到欧氏意义更紧凑但图结构更差的划分。改用模块度后，参数和重启结果都可以在无标签条件下选择，准确率和稳定性同时提高。

第三个认识是对 DBSCAN 必须同时报告覆盖率和全样本准确率。只报告非噪声样本上的条件准确率会掩盖大量样本被拒绝的问题。完整实验应主动呈现算法局限，而不是只选择有利指标。

9 结论与展望

本文完成了一个可复现的手写数字无监督聚类系统。通过倾斜校正、局部尺度谱图、模块度重启选择和邻域一致性细化，最终 ACC 达到 95.55%，明显优于 K-means、DBSCAN、GMM 和标准谱聚类。消融、敏感性和稳定性实验共同验证了改进方法的有效性。

方法的主要局限是需要构建样本图并进行特征分解，数据规模较大时计算和存储成本会增加；此外，邻域多数投票可能对极少数真实小簇产生过度平滑。未来可研究近似

近邻、Nyström 谱近似、置信度约束的自适应细化，以及在更大手写数据集上的泛化能力。

参考文献

- [1] J. MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pages 281–297, 1967.
- [2] David Arthur and Sergei Vassilvitskii. k-means++: The advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, pages 1027–1035, 2007.
- [3] Martin Ester, Hans-Peter Kriegel, Jorg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, pages 226–231, 1996.
- [4] Jianbo Shi and Jitendra Malik. Normalized cuts and image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(8):888–905, 2000.
- [5] Andrew Y. Ng, Michael I. Jordan, and Yair Weiss. On spectral clustering: Analysis and an algorithm. In *Advances in Neural Information Processing Systems 14*, pages 849–856, 2002.
- [6] Lihi Zelnik-Manor and Pietro Perona. Self-tuning spectral clustering. In *Advances in Neural Information Processing Systems 17*, pages 1601–1608, 2004.
- [7] M. E. J. Newman. Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, 103(23):8577–8582, 2006.
- [8] Harold W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1–2):83–97, 1955.
- [9] Lawrence Hubert and Phipps Arabie. Comparing partitions. *Journal of Classification*, 2:193–218, 1985.
- [10] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pages 886–893, 2005.

- [11] Peter J. Rousseeuw. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65, 1987.